Music Recommend

HTTPS://GITHUB.COM/YOON1717/YOONCALENDAR

윤 가영

Contents

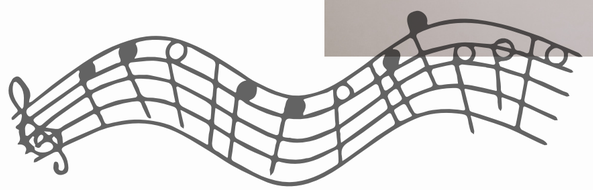

사용자의 입력에 따른 음악 추천 기능을 위한

멜론 사이트 크롤링으로 데이터를 수집,
NPL 자연어 처리와 임베딩을 통해
유사도가 높은 음악을 추천

사용자에게
듣고 싶은 노래에 대한 설명
혹은 어떤 기분인지
텍스트를 입력 받습니다.

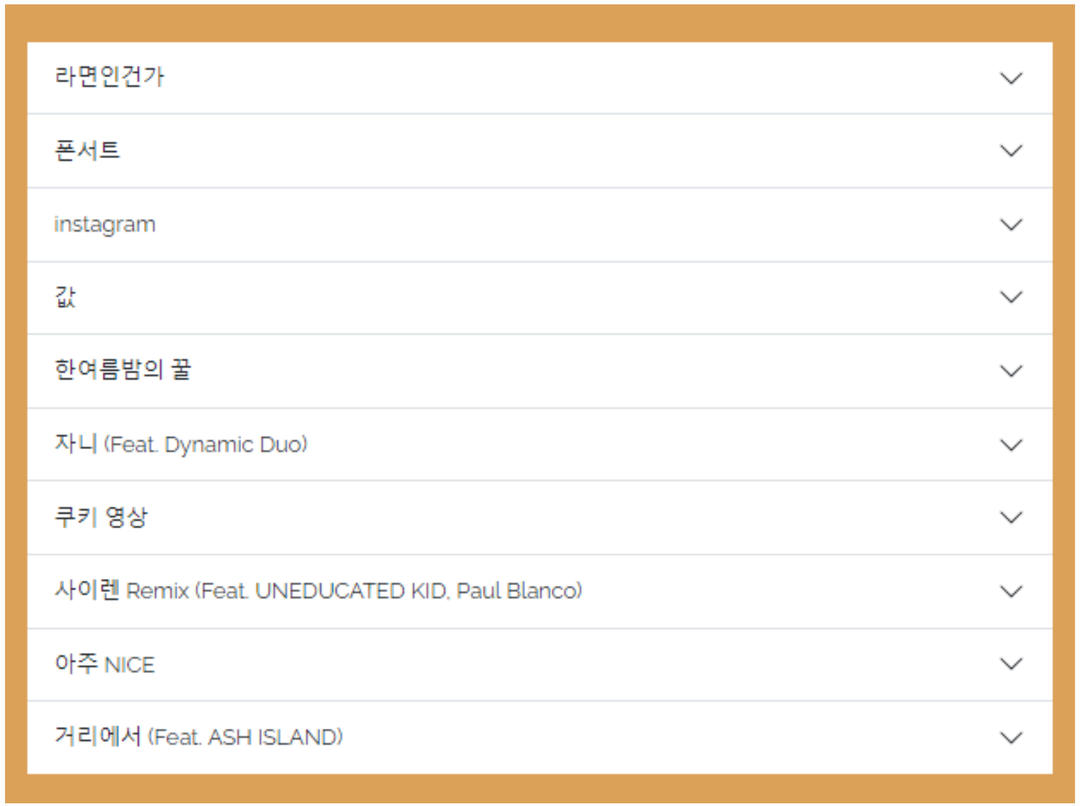

사용자가 입력한 텍스트와
가사의 유사도가
가장 높은 10개의 곡을 추천합니다.

02. 주요 기능

추천 리스트의
노래를 누르면
해당 곡의 가사 정보와
melon 의 노래 정보 페이지로
연결되는 버튼이 있습니다.

음악 추천 아코디언 옆에는
사용자의 입력어와
가사의 유사도가 높은 50개 곡의
장르 정보를 방사형 그래프로
시각화 해 보여줍니다.

03. 프로젝트 핵심 소스 / 웹 크롤링

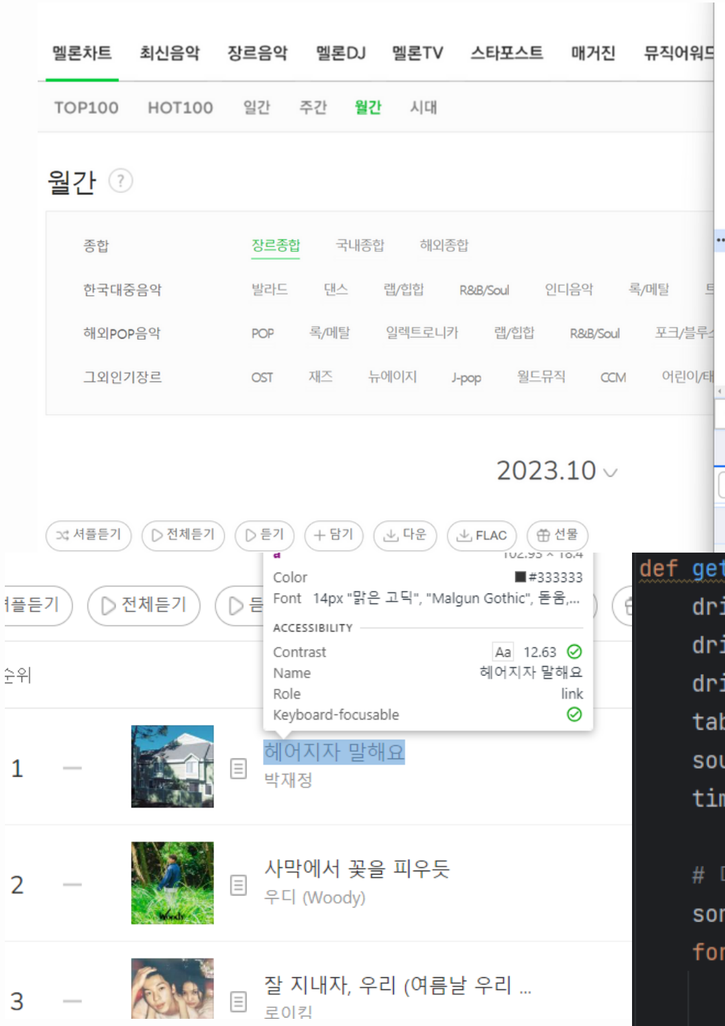

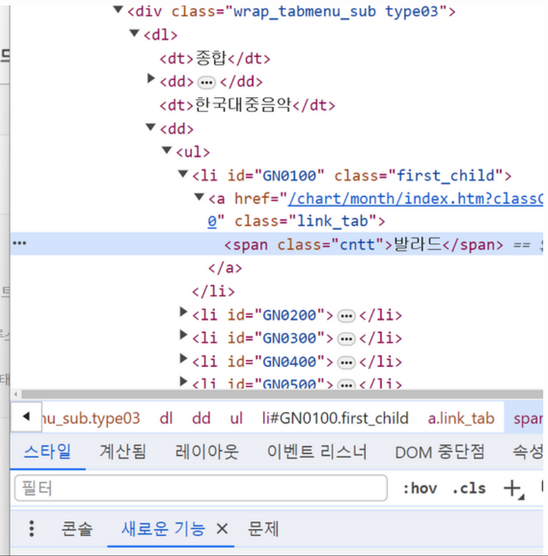


```
# 'GN0100' : 발라드
# 'GN0200' : 댄스
# 'GN0300' : 랩/힙합
# 'GN0400' : R&B/SOUL
# 'GN0500' : 인디음악
# 'GN0600' : 록/메탈
# 'GN0700' : 트로트
# 'GN0800' : 포크/블루스
```

```python
def get_genre(query):
    driver = webdriver.Chrome("../chromedriver.exe")
    driver.implicitly_wait(3)
    driver.get(url + query)
    table = driver.find_element(By.TAG_NAME,'table')
    soup = BeautifulSoup(driver.page_source, 'html.parser')
    time.sleep(1)

    # 데이터 수집 및 리스트에 추가
    song_elements = soup.find_all('tr', attrs={'data-song-no': True})
    for song in song_elements:
        song_no = song['data-song-no']
        print(f'data-song-no: {song_no}')
        song_list.append({'keyword': query, 'song-no': song_no})
```

멜론 차트 페이지의
html 요소 속성 분석

selenium의 webdriver를 활용
8개 장르에 대한
100개 곡 고유번호 수집

pandas를 활용
장르 | 곡 번호
xlsx 파일로 저장

03. 프로젝트 핵심 소스 / 웹 크롤링

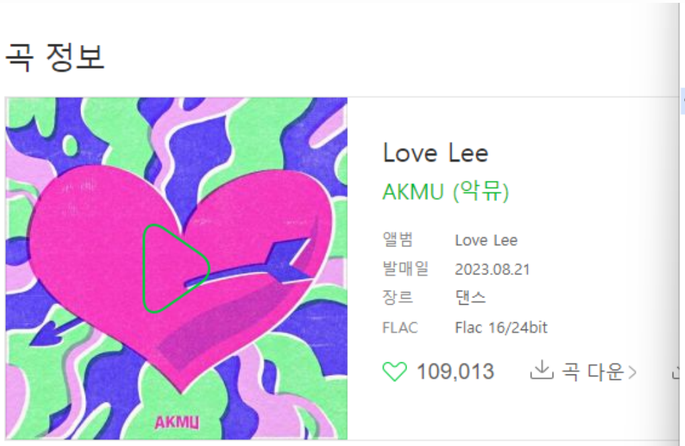

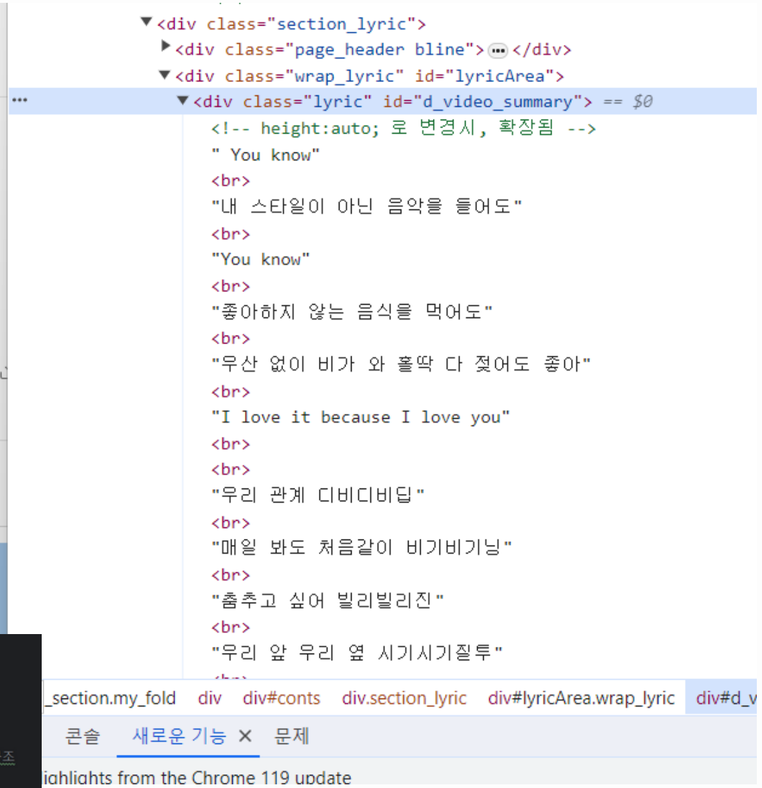

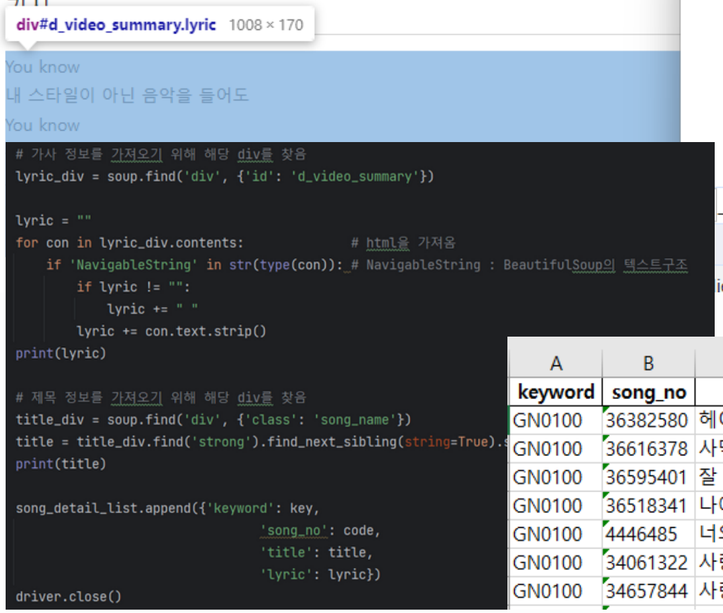

keyword	song_no	title	lyric
GN0100	36382580	헤어지자 말해요	헤어지자고 말하려 오늘 너에게 가다가 우리 추억 생각해 봤어 처음 본 네 얼굴 마주친
GN0100	36616378	사막에서 꽃을 피우듯	리에 첫눈을 보다가 문득 고백했던 그 순간 가보고 싶었던 식당 난생처음 준비한 선물
GN0100	36595401	잘 지내자, 우리 (여름날	헤어지자 말해요 나는 사실 그대에게 좋은 사람이 아녜요 그대 이제 날 떠난다 말해요
GN0100	36518341	나에게 그대만이	면 나는 어쩔 수 없을 걸 문득 너의 사진 보겠지 새로 사귄 친구 함께 웃음 띤 네 얼굴 !
GN0100	4446485	너의 모든 순간	먼저 헤어지자 말해요 나는 사실 그대에게 좋은 사람이 아녜요 그대 이제 날 떠난다 말
GN0100	34061322	사랑은 늘 도망가	볼 수 있을까 이기적인 거 나도 잘 알아 그땐 그럴 수밖에 없던 어린 내게 한 번만 더 ㄱ
GN0100	34657844	사랑인가 봐	게 좋은 사람이 되고 싶었어 영영 다신 못 본다 해도 그댈 위한 이 노래가 당신을 영원

멜론 개별 곡 페이지
html 요소 속성 분석

selenium의 webdriver를 활용
수집한 곡 번호 해당 페이지
제목, 가사 수집

html 문법의 가사
BeautifulSoup을 활용
태그 제거

xlsx 파일로 저장

```python
for i, line in enumerate(lyrics):
    try:
        d = okt.pos(line, norm=True, stem=True)
        r = []
        for word in d:
            if not word[1] in ['Josa', 'Eomi', 'Punctuation']:
                r.append(word[0])
        rl = (" ".join(r)).strip()
        result.append(rl)
        result_titles_list.append(titles_list[i])
        result_keyword_list.append(keyword_list[i])
        result_song_no_list.append(song_no_list[i])
    except Exception as ee:
        print(ee)
```

	A	B	C	D	E	F	G	H
	genre	song_no	title	analyzed_lyric				
	GN0100	36382580	헤어지자 말해요	헤어지자 말 하다 오늘 너 가다가 우리 추억 생각 하다 보다 처음 보다 네 얼굴 마주치				
	GN0100	36616378	사막에서 꽃을 피우듯	거리 첫 눈 보다 문득 고백 하다 그 순간 가보다 싶다 식당 난생처음 준비 선물 고맙다				
	GN0100	36595401	잘 지내자, 우리 (여름날 우	말 하다 나 사실 그대 좋다 사람 아 녜 그대 이제 날 떠나다 말 하다 잠시 이 행복 느끼				
	GN0100	36518341	나에게 그대만이	사진 보다 새롭다 사귀다 친구 함께 웃음 띤 네 얼굴 보다 말 하다 수 없다 묘 감정 들				
	GN0100	4446485	너의 모든 순간	좋다 사람 아 녜 그대 이제 날 떠나다 말 하다 잠시 이 행복 느끼다 고맙다 하다 번은				
	GN0100	34061322	사랑은 늘 도망가	다 어리다 내다 하다 번만 더 기회 주다 그 대다 정말 사랑 하다 말 하다 나 사실 그대				
	GN0100	34657844	사랑인가 봐	위 이 노래 당신 영원하다 사랑 하다 테				

수집한 원본가사 형태소 분석
konlpy Okt 활용
조사, 어미, 문장부호 제거

analyzed_lyric 컬럼 생성

csv 파일로 저장

```python
# CSV 파일 읽기
file_path = 'analyzed.csv'
df = pd.read_csv(file_path, encoding='cp949')

# UTF-8 인코딩으로 저장
output_file_path = 'analyzed_utf8.csv'
df.to_csv(output_file_path, index=False, encoding='utf-8')
```

csv 파일 읽어오는 것에서
지속적인 에러 발생

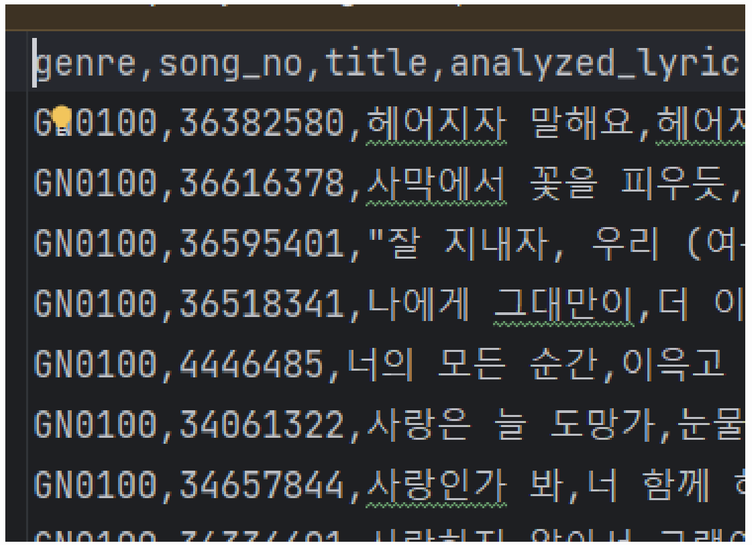

encoding cp949로 되어있음
확인

utf-8로 인코딩 후 저장

```
df = pd.read_csv('analyzed_utf8.csv')
df.head()

data = df['analyzed_lyric'].values
okt = Okt()
result = []
for line in data:
    d = okt.pos(line, norm=True, stem=True)
    r = []
    for word in d:
        if not word[1] in ['Josa', 'Eomi', 'Punctuation']:
            r.append(word[0])
    result.append(r)
fasttext_model = fasttext.FastText(result, vector_size=100, window=8, min_count=2, sg=1)
fasttext_model.save('music.model')
```

단어 추출하여 리스트에 저장

전처리된 데이터를 사용하여
FastText 모델을 학습

music.model로 저장

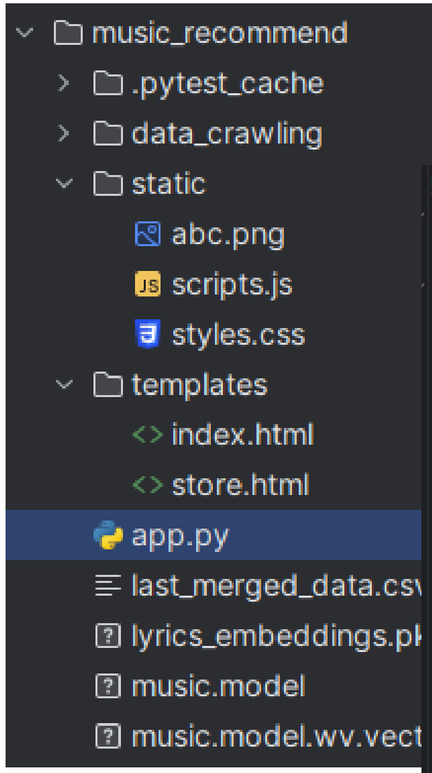


```python
@app.route( rule: "/", methods=["GET", "POST"])
def index():

    if request.method == "POST":
        # 폼 데이터를 처리하고 원하는 동작을 수행하세요
        content = request.form["content"]
        top_10_songs = remove_duple_top_songs( num: 10, content)
        top_50_songs = get_top_songs( num: 50, content)
        gen_rate = get_genre_rate(top_50_songs)
        img_data = make_graph(gen_rate)

        return render_template( template_name_or_list: "store.html"
                                , top_10_songs=top_10_songs
                                , top_50_songs=top_50_songs
                                , gen_rate=gen_rate
                                , img_data=img_data)  # top_songs 변수를 store.html로 전달
    else:
        return render_template("index.html")  # top_songs

@app.route( rule: "/store", methods=["GET", "POST"])
def store():
    # 다른 페이지(예: store.html)의 뷰 코드
    return render_template("store.html")
```

웹 서비스를 위해
flask 활용

```python
def get_embedding(text, model):
    words = text.split()
    word_embeddings = [model.wv[word] for word in words if word in model.wv]
    if not word_embeddings:
        return np.zeros(model.vector_size)
    return np.mean(word_embeddings, axis=0)

def preprocess_text(text):
    okt = Okt()
    result = []
    d = okt.pos(text, norm=True, stem=True)
    r = []
    for word in d:
        if not word[1] in ['Josa', 'Eomi', 'Punctuation']:
            r.append(word[0])
    # 토큰화된 단어들을 다시 문자열로 결합
    return ' '.join(r)
```

사용자에게 입력 받은 텍스트
model에 학습시킨
가사 데이터와 동일하게 전처리

```python
def remove_duple_top_songs(num, content):
    # 사용자 입력의 임베딩 생성
    user_embedding = get_embedding(preprocess_text(content), model)
    # 저장된 임베딩 로드
    lyrics_embeddings = pd.read_pickle('lyrics_embeddings.pkl')
    # 코사인 유사도 계산
    similarity_scores = cosine_similarity(X: [user_embedding], list(lyrics_embeddings['embedding']))[0]
    # 유사도 점수에 따라 내림차순으로 정렬
    lyrics_data['similarity_score'] = similarity_scores
    sorted_songs = lyrics_data.sort_values(by='similarity_score', ascending=False)
    # 중복 song_no를 제거하고 상위 10개의 곡 선택
    top_songs = []
    seen_song_no = set()  # 이미 선택한 song_no를 추적하기 위한 집합
    for _, row in sorted_songs.iterrows():
        song_no = row['song_no']
        if song_no not in seen_song_no:
            top_songs.append(row.to_dict())
            seen_song_no.add(song_no)
            if len(top_songs) == num:
                break
    return top_songs
```

10개 곡 추천을 위한
유사도 가장 높은 순위 매김
(장르 중복) 중복 song_no 제거

10개 곡 화면에 출력

```python
def make_graph(rate):
    genre_names = {...}

    # 장르 코드를 장르명으로 변환
    for item in rate:
        item['Genre'] = genre_names.get(item['Genre'], item['Genre'])
    # 'Genre'와 'Ratio'를 추출하여 리스트로 저장
    genre_list = [item['Genre'] for item in rate]
    ratio_list = [item['Ratio'] * 100 for item in rate]
    # categories에 'Genre' 추가
    categories = [*genre_list, genre_list[0]]
    # grade1에 'Ratio' 추가
    grade1 = [*ratio_list, ratio_list[0]]
    # 나머지 그래프 그리는 코드
    label_loc = np.linspace(start=0, stop=2 * np.pi, num=len(grade1))
    plt.figure(figsize=(8, 8))
    ax = plt.subplot(polar=True)
    plt.xticks(label_loc, labels=categories, fontsize=13)
    ax.plot(label_loc, grade1, label='my mode', linestyle='dashed', color='lightcoral')
    ax.fill(label_loc, grade1, color='lightcoral', alpha=0.3)
    ax.legend()
    img_buffer = io.BytesIO()
    plt.savefig( *args: img_buffer, format='png')
    img_buffer.seek(0)
    img_data = base64.b64encode(img_buffer.read()).decode()
    # 이미지 데이터를 HTML 페이지로 전달
    return img_data
```

```python
def get_genre_rate(list):
    genre_rate = []  # 결과를 담을 리스트 초기화
    for song_info in list:
        genre = song_info['genre']
        genres_list.append(genre)
    print(genres_list)
    # 각 장르의 갯수 계산
    genre_counts = Counter(genres_list)
    # 전체 곡 수
    total_songs = len(genres_list)
    # 각 장르의 비율 계산
    genre_ratios = {genre: count / total_songs f
    # 결과 출력
    for genre in possible_genres:
        count = genre_counts.get(genre, 0)
        ratio = round(genre_ratios.get(genre, 0.0),2)
        print(f'Genre: {genre}, Count: {count}, Ratio: {ratio:.2%}')
        genre_rate.append({'Genre': genre, 'Count': count, 'Ratio': ratio } )
    return genre_rate
```

장르 추천을 위한
유사도가 높은 50개 곡의
장르 비율

matplotlib 활용
방사형 그래프 이미지 저장
화면에 출력

04. 향후 개선점

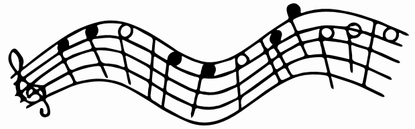

한정적인
데이터

melon 월간 차트
8개 장르 100개 곡

학습의 기준이 될
데이터가 한정적

풍부한
데이터

melon
다양한 차트에서
song_no 수집해서

다양하고
정확한 곡 추천

관련 없는
추천

사용자의 입력과
유사성이 떨어지는
곡 추천

정확한
추천

Word2Vec,
GloVe와 같은
다양한 모델 시도

하이퍼 파라미터
튜닝

Thanks!

YOON
GAYOUNG